Structured Query Language

Основные моменты на примере PSQL

Установка Postgres и создание новой базы данных

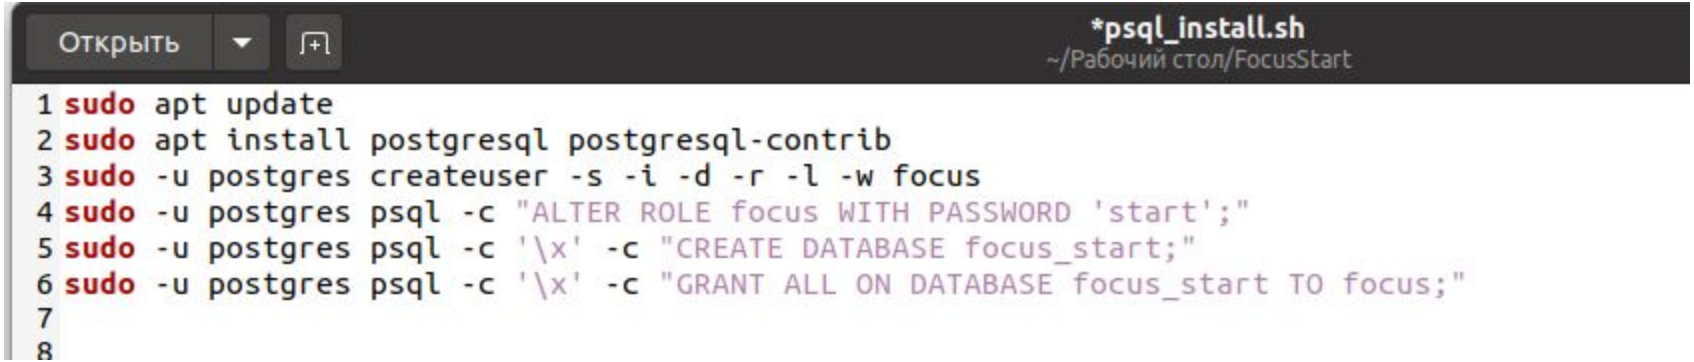

ASHRAE - Great Energy Predictor III

weather_[train/test].csv

Weather data from a meteorological station as close as possible to the site.

- `site_id`
- `air_temperature` - Degrees Celsius
- `cloud_coverage` - Portion of the sky covered in clouds, in oktas
- `dew_temperature` - Degrees Celsius
- `precip_depth_1_hr` - Millimeters
- `sea_level_pressure` - Millibar/hectopascals
- `wind_direction` - Compass direction (0-360)
- `wind_speed` - Meters per second

train.csv

- `building_id` - Foreign key for the building metadata.
- `meter` - The meter id code. Read as `{0: electricity, 1: chilledwater, 2: steam, 3: hotwater}`. Not every building has all meter types.
- `timestamp` - When the measurement was taken
- `meter_reading` - The target variable. Energy consumption in kWh (or equivalent). Note that this is real data with measurement error, which we expect will impose a baseline level of modeling error. UPDATE: as discussed here, the site 0 electric meter readings are in kBTU.

building_meta.csv

- `site_id` - Foreign key for the weather files.
- `building_id` - Foreign key for `training.csv`
- `primary_use` - Indicator of the primary category of activities for the building based on EnergyStar property type definitions
- `square_feet` - Gross floor area of the building
- `year_built` - Year building was opened
- `floor_count` - Number of floors of the building

Создадим таблицу из файла

```
create table weather_train (
        site_id SERIAL NOT NULL,
        timestamp_measurement timestamp without time zone not null DEFAULT NULLIF('0000-00-00 00:00:00','0000-00-00
00:00:00')::timestamp,
        air_temperature float(8),
        cloud_coverage float(8),
        dew_temperature float(8),
        precip_depth_1_hr float(8),
        sea_level_pressure float(8),
        wind_direction float(8),
        wind_speed float(8)
);

COPY weather_train(
        site_id,
        timestamp_measurement,
        air_temperature,
        cloud_coverage,
        dew_temperature,
        precip_depth_1_hr,
        sea_level_pressure,
        wind_direction,
        wind_speed
)
FROM '/home/lapltop/Рабочий стол/FocusStart/weather_train.csv' DELIMITER ',' CSV HEADER;
```

Подготовка рабочей среды

1. Создаем окружение.
2. Устанавливаем туда
   - ***psycopg2-binary*** - для соединения с базой данных
   - ***pandas*** есть метод в котором реализован функционал отправки запросов к базе.
   - ***jupyter notebook*** просто для удобства =)
3. Поднимаем jupyter из окружения.

Напишем вспомогательную функцию для отправки запросов

```
def send_sql_query(query):
    params = {
        'database': 'focus_start',
        'host': 'localhost',
        'user': 'focus',
        'password': 'start'
    }
    conn = psycopg2.connect(**params)
    raw_data = pd.read_sql_query(query, conn)
    conn.close()
    return raw_data
```

Основные команды SQL

```
SELECT * FROM table_name
  WHERE num = 1 AND (id > 5 OR id
 < 2 );
```

```
+------+------+
| num  | id   |
+------+------+
|    1 |    1 |
|    1 |    7 |
|    1 |   42 |
+------+------+
```

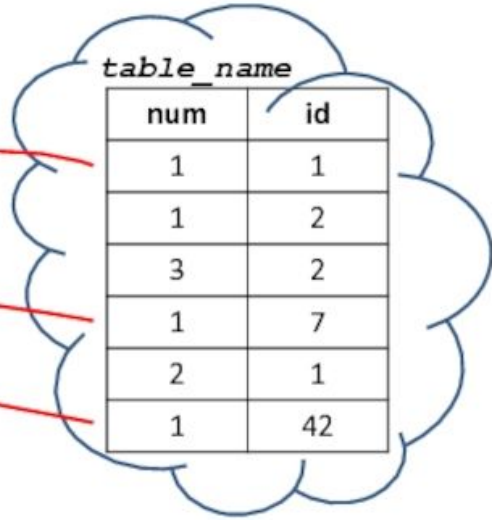

Давайте испытаем нашу функцию!

Задача

Посчитайте количество зданий, где установлено 2 и более типа счетчиков.

SQL JOINS

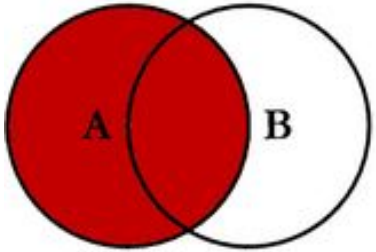


```
SELECT <select_list>
FROM TableA A
LEFT JOIN TableB B
ON A.Key = B.Key
```

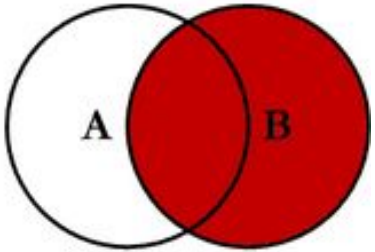


```
SELECT <select_list>
FROM TableA A
RIGHT JOIN TableB B
ON A.Key = B.Key
```

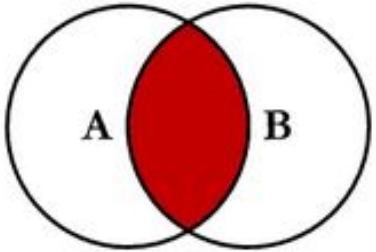


```
SELECT <select_list>
FROM TableA A
INNER JOIN TableB B
ON A.Key = B.Key
```

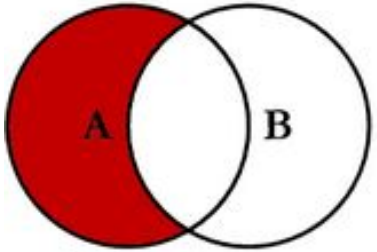


```
SELECT <select_list>
FROM TableA A
LEFT JOIN TableB B
ON A.Key = B.Key
WHERE B.Key IS NULL
```

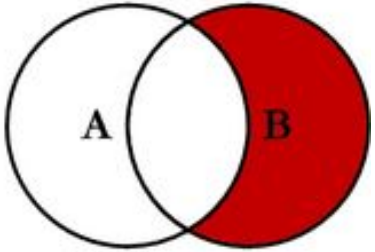


```
SELECT <select_list>
FROM TableA A
RIGHT JOIN TableB B
ON A.Key = B.Key
WHERE A.Key IS NULL
```

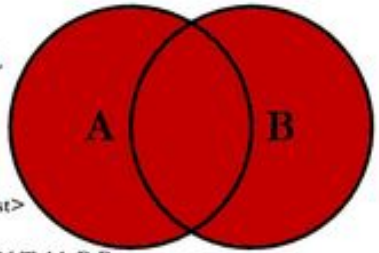


```
SELECT <select_list>
FROM TableA A
FULL OUTER JOIN TableB B
ON A.Key = B.Key
```

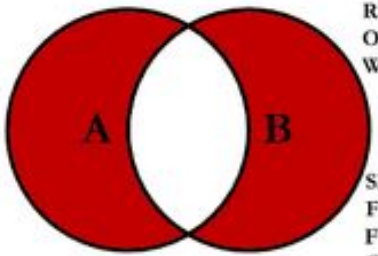


```
SELECT <select_list>
FROM TableA A
FULL OUTER JOIN TableB B
ON A.Key = B.Key
WHERE A.Key IS NULL
OR B.Key IS NULL
```

Задача:

Представим, что мы решили построить модель на этих данных и хотим собрать все признаки в кучу за последние день 2016 года. (если менее 5гб свободной оперативки, можете добавить ещё фильтры к основной таблице)

Соединить между собой все три таблицы (***measurement_results, building_metadata, weather_train***), с фильтром по дате от 30 декабря 2016 года.

*Учитывайте, что **measurement_results** является основной таблицей, где находится целевая переменная.*

Задача с WITH

Задача

1. *Давайте по генерируем гипотезы на основе наших данных! (не более 2ух - **не нужно придумывать, те которые сложно посчитать**).*
2. *Попробуем используя конструкцию WITH в одном запросе получить:*
   2.1 Основную часть данных, которая состоит из:
      - идентификатор здания
      - тип счетчика
      - целевая переменная (показания счетчика)
   2.2 Запрос насчитывающий признак №1
   2.3 Запрос насчитывающий признак №2
3. *Объединить все в один набор данных.*

Оконные функции бывают...

- Агрегатные функции;
- Ранжирующие функции;
- Функции смещения;
- Аналитические функции.

Обычный запрос

Запрос с оконной функцией

http://thisisdata.ru/blog/uchimsya-primenyat-okonnyye-funktsii/?utm_source=telegram.org&utm_medium=referral

Агрегатные функции

- **SUM** – возвращает сумму значений в столбце;
- **COUNT** — вычисляет количество значений в столбце (*значения NULL не учитываются*);
- **AVG** — определяет среднее значение в столбце;
- **MAX** — определяет максимальное значение в столбце;
- **MIN** — определяет минимальное значение в столбце.

Кумулятивная сумма

Задание

Посчитайте накопительную сумму(используя оконную функцию) для каждого здания и типа счетчика.

Ранжирующие функции

- **ROW_NUMBER** – функция возвращает номер строки и используется для нумерации;
- **RANK** — функция возвращает ранг каждой строки. В данном случае значения уже анализируются и, в случае нахождения одинаковых, возвращает одинаковый ранг с пропуском следующего значения;
- **DENSE_RANK** — функция возвращает ранг каждой строки. Но в отличие от функции RANK, она для одинаковых значений возвращает ранг, не пропуская следующий;
- **NTILE** – это функция, которая позволяет определить к какой группе относится текущая строка. Количество групп задается в скобках.

Drop duplicates and keep = last

Задание

*Напишите запрос(используя оконные функции), который уберет все дублирующие записи по полям **building_id, meter** и вернет самое **новое** значение.*

Функции смещения

- **LAG или LEAD** – функция LAG обращается к данным из предыдущей строки окна, а LEAD к данным из следующей строки. Функцию можно использовать для того, чтобы сравнивать текущее значение строки с предыдущим или следующим. Имеет три параметра: столбец, значение которого необходимо вернуть, количество строк для смещения (*по умолчанию 1*), значение, которое необходимо вернуть если после смещения возвращается значение NULL;
- **FIRST_VALUE** или **LAST_VALUE** — с помощью функции можно получить первое и последнее значение в окне. В качестве параметра принимает столбец, значение которого необходимо вернуть.

Аналитические функции

- **CUME_DIST** — вычисляет интегральное распределение (относительное положение) значений в окне;
- **PERCENT_RANK** — вычисляет относительный ранг строки в окне;
- **PERCENTILE_CONT** — вычисляет процентиль на основе постоянного распределения значения столбца. В качестве параметра принимает процентиль, который необходимо вычислить;
- **PERCENTILE_DISC** — вычисляет определенный процентиль для отсортированных значений в наборе данных. В качестве параметра принимает процентиль, который необходимо вычислить.

Кастомные функции

```
CREATE FUNCTION is_more_average(building bigint, meter_type bigint, meter_reading_float float(8))
RETURNS boolean AS $$
DECLARE average_meter_reading float(8);
DECLARE answer boolean;

BEGIN
        SELECT
            AVG(mr.meter_reading) INTO average_meter_reading
        FROM measurement_results as mr
        WHERE mr.meter = $1 AND mr.building_id = $2;

        if average_meter_reading <= $3 then
                SELECT TRUE INTO answer;
        else
                SELECT FALSE INTO answer;
        end if;
        RETURN answer;
END;
$$ LANGUAGE PLpgSQL;
```